

约束层： 自主智能体、确定性账本，与机器后果的缺失基底

Xinhao Zheng*

独立研究者

2026 年 6 月 12 日

摘要

一个自主软件智能体如今能够决策，却无法绑定。当前的模型会规划一笔交易、起草一份合同、下达一条支付指令，但它所产出的任何东西本身都不可问责：其行为是非确定性的，它没有抵押，它无法证明自己停留在被授予的权限之内，也无法使任何结果不可逆。这一缺口是结构性的，而非规模问题——更强的模型决策更好，却并不因此变得可绑定。我们论证：所缺的这项能力——受规则约束的、可证明的、可清算的后果——恰恰是某一类公共账本所供给的；二者是互补而非竞争：生成式系统恰恰在账本僵硬而受规则治理之处开放而不受约束，而对承载后果的自主性而言，二者缺一不可。我们给出这一缺口的解剖；陈述一个账本要充当智能体的约束层必须同时满足的五项性质——可证安全的共识；使「本地核查的动作等于全局清算的动作」的确定性结算；表达力足以承载私密合规谓词的证明；为中立性付费却不产生所有者的经济；以及能够自我修订的规则——并说明为何主流账本设计至多只满足其中若干项。随后，我们以一个已部署的架构对照这五项做个案分析，依据是架构设计而非市场表现，并描述当权限被编译为可核查的策略、结算本身即为审计时，智能体商业所呈现的形态。两种常被一并归为风口的技术，实为同一缺失原语的两半：会决策的机器，以及一个能让其决策承载后果的基底。决策正在变得充裕；后果尚未；而构建后者，才是更难、也更被忽视的那一半。

关键词 自主智能体；可验证计算；确定性结算；零知识证明；智能合约；委托；AI 安全。

1 引言

自主智能体的难题，不在于它可能思考得糟糕，而在于它能够行动却不被绑定。一个接入工具的语言模型会读取行情、选择对手方、确定仓位、并发出转移资金的指令——而在这一连串过程中的任何一点，都没有任何东西把它约束在被允许做的事情上、以陌生人可核查的形式记录它实际

*通讯邮箱: xinhaozheng.vx@outlook.com。代码与数据: <https://github.com/xinhao-zheng/constraint-layer>。本稿为中文对照版本；arXiv 正式投稿以英文版为准。

做了什么、或使结果成为最终。能力研究正把精力倾注于自主性的前半，即决策；而让一个决策真正算数的后半，却没有可与之相比的纲领——因为它从一开始就不是模型的属性。

这后半，在经济学里有一个比它更古老的名字：让彼此不信任的各方仍能交易的机制。制度的存在，正是为了降低这样做的成本 [1]，而信任是让整个系统得以运转的润滑剂 [2]。对人类行为者而言，这套机制是环境性的——合同、登记处、法院、声誉、后果的威慑——而一个自主智能体对此一无所继承。它没有会因劣行受损的声誉，没有法院能触及的资产，没有在多次运行间持续承担责任的身份。关于代理式系统的文献已经清点由此产生的种种风险 [3, 4]；我们将它们读作同一处缺失的症状。智能体是一种决策的能力，却没有后果的能力。

本文做三件事。第一 (§2)，给出这一缺失的解剖：当智能体的决策要去绑定其他各方时，它具体地、结构性地缺少哪些东西——并论证其中没有一项会因模型变大而被弥合。第二 (§3-§4)，指认那个互补物。一个合适类型的公共账本，不是与模型争夺地位的另一个决策者；它是一个后果的基底——在智能体非确定之处它确定，在智能体开放之处它受规则治理，在智能体只能断言之处它能使结果可证且最终。这种契合贴近到看起来像是设计好的：智能体供给账本所不能（开放式决策），账本供给智能体所不能（被绑定、可证、已清算的后果）。但「一个账本」还不够；只有同时具备五项特定性质的账本，才能在不重新引入它本要消除的可信第三方的前提下绑定一个智能体，而最知名的设计至多满足其中若干项。第三 (§5-§6)，以一个已部署的架构对照这五项要求做一个完整个案——依据文档化的设计，而非市场表现——并描述当智能体的权限被编译为其对手方可以核查的谓词、结算本身即是审计轨迹时，商业所呈现的形态。

本文的主张刻意收窄，且在形式上可证伪。它不是说区块链是好的，也不是说任何代币会升值；个案分析 (§5) 明确指出架构不等于采用，而 §7 写明了何者将推翻本论题。主张是：把生成式决策与可验证的、确定性的后果配对，是一个真实的技术方向而非口号；它由自主性到来的方式所迫成；而工程难度的大半，都在后果这一侧——这恰是当下对「更大的决策者」的热情所未触及的。

2 未被绑定的智能体

当一个自主智能体的输出意在移动资金、绑定对手方、或承载法律效力时，它究竟缺什么？六样东西，没有一样是智力缺陷。

非确定性。 模型的输出是一次采样，而非一个函数。重跑一遍，答案可能改变；而一笔支付或一次合约执行不能接受这一点——它要求该操作恰好意味着一件事，且任何观察者都能逐位重算出同样的结果。确定性不是更强的采样器会收敛到的某种品质；它是另一种体制，而承载后果的行动只存在于其中。

无构造性的规则绑定。 可以告知智能体一条规则——支出上限、允许的对手方集合、辖区约束——它也许会以概率方式遵守。但不存在任何一个层面，使这条规则是绑定的而非建议性的。用与被约束行为相同的介质写就的护栏，只是建议；承载后果的委托所需要的，是一条智能体无法违反

的规则——因为违反会在别处被拒绝，而不仅仅是在模型内部被劝阻。

无法证明自身的行为。 事后，智能体无法证明自己是在授权范围内行动的；它只能断言，而它的断言恰恰是机器生成如今可零成本量产的那种流利、不可证伪的人造物。事后通过检视输出来发现违规，在极限意义上并不可靠：基于分类器的生成内容检测随模型变强而向随机水平衰减 [5]，强水印在合理假设下也存在一般化的擦除 [6]。必须从智能体自身证词中重建的信任，根本不是信任。

无受界、可委托的权限。 今天把权限交给智能体，就是把一个凭证——一个 API 密钥、一个钱包种子——交给它，而这凭证实际上是无界的：持有者能做底层账户所能做的一切。没有原生的方式去授予这么多、且仅此为限，使该边界由对手方强制执行、而非由委托人寄望。没有可强制边界的委托不是委托，而是放弃。

无结算。 智能体能算出一笔转移应当发生；它无法使之已经发生。最终性——动作越过此点便不能被悄然撤销或重排——是结算系统的性质，而非推理器的性质。没有它，每一个下游方都必须为「智能体所做之事将被修订」的风险定价，而这风险是对每一次交互的征税。

无可问责的身份。 当被问到「这是什么，谁在背后？」智能体没有结构性的答案。它不是人，不抵押任何东西，它与部署它的委托人之间的关系，对对手方而言不可验证。最古老的非正式验证——发问，再看回答是否自洽——如今筛选的是更好的生成器，而非诚实的行为者。

这些都不是认知的失败，也不会随认知增长而缩小；能力翻倍的模型决策更好，却并不更可绑定。它们是后果的失败：是智能体无法使其决策受规则约束、可证明、最终、且可归属。每一项，都是某一类系统已经工程化了十五年之久的某项性质的镜像。

3 确定性的互补物

智能体所缺的那些性质，正是公共账本的定义性性质。这不是一桩值得赞叹的巧合，而是一种值得使用的互补：两个系统恰好在彼此不相交之处各自强大。生成式模型开放、富创造力、不受约束，且在有人供给规则之前没有规则；账本僵硬、受规则治理、确定，且其所做的一切都关乎证明与可证性。对承载后果的自主性而言，二者皆不充分。账本不决策任何事——没有提出动作的行为者，它便是惰性的。智能体不结算任何事——没有使动作绑定的基底，它便不可问责。把生成性置于一侧、可绑定性置于另一侧（图 1a），设计目标便是二者单独都不占据的右上区域：一个会提出的智能体，置于一个会绑定的基底之上。

具体地读，基底执行智能体所不能的四项功能。它在事前约束。一个动作可以被做成携带一份证明，证明它满足委托人的策略——这笔转移在预算内、这个对手方被许可、这次披露合法——由接收方在其生效前核查，沿袭「自携证明的代码」的谱系：生产者把不受信的指令连同其安全性证明一并交付，消费者核查证明而非信任生产者 [7]。智能体的权限于是成为陌生人可以验证的对象，




图 1：互补性。(a) 按生成性（开放式决策的能力）对可绑定性（使决策可证、可清算、最终的能力）放置各系统。生成式智能体处于高生成性、近零可绑定性；仅记值账本与账户模型账本处于低生成性、部分可绑定性；目标——可信的自主性——只有将智能体与一个确定性的、自携证明的基底配对才能达到。(b) 智能体的动作生命周期。生成的、非确定的一步（决策）属于模型；受规则约束的、确定的诸步（证明、结算、审计）属于账本。约束层附着于二者边界，在此强制由委托人编译的策略谓词 φ 。示意图。

表 1：分工。智能体唯一的原生强项，正是账本唯一的原生弱项，反之亦然；承载后果的自主性需要两列同时具备。

能力	自主智能体	公共账本
开放式决策	原生	无
确定性 / 可重放	否	是
构造性规则绑定	仅建议	规则即代码
证明自身行为	只能断言	自携证明
不可逆结算	否	是
受界、可委托权限	无界	策略谓词
可问责身份	无抵押	密钥、公共记录

而非委托人寄望的某种秉性。它结算。在确定性基底上，被核查的动作就是成为最终的动作，中间没有可供修订的缝隙。它把合规变成谓词。由于证明可以是零知识的，智能体能证明自己满足某条规则而不暴露其背后的数据 [8, 9]——越过辖区门槛、持有足额抵押、已成年——于是结算携带对手方所需的证据、且仅此而已，验证不再是监控。它原生地承载被委托的权限。支撑这件事的机制正在被标准化：智能体支付协议把一笔购买锚定到一串密码学签名的授权凭证（*mandate*）——意图、购物车、支付——使权限建立在「委托人批准了什么」的可验证、不可抵赖的证据之上，而非建立在模型的概率性输出之上 [10]；一套 HTTP 原生方案让智能体在一次交互中为资源付费并附上支付证明 [11]；带会话密钥的账户抽象则让委托人铸造一份只限于某个对手方、某个金额、某段短有效期的凭证，边界在执行时被强制而非被信任 [12]。智能合约在多年前就供给了所缺的词汇——把合同条款表示为可执行对象 [13]——而它所带来的验证成本下降，是这项技术的原始经济性之一 [14]。要点不在于其中任何一项孤立地说是新的；而在于，组装起来，它恰恰是智能体所缺的那项后果的能力。

4 账本要绑定一个智能体须成为什么

「一个账本」太过笼统。一个意在大规模绑定智能体的基底，必须同时满足五项要求；缺其一，要么智能体逃出约束，要么一个可信第三方被悄悄重新引入到下一层——只是排版更精美。诸要求从第一性原理陈述；§5 以一个已部署系统对照之，表 2 给出映射。

R1 —— 可证安全的共识。 一个以「核查这个」取代「信我」为业的基底，不能把自身的安全性建立在「运营者看起来诚实」之上。基础层的安全本身必须是一个可核查的主张，化归为既述假设与敌手模型并加以证明——正如那些在显式同步与腐化假设下确立其保证的权益证明协议 [15, 16]。一个以声誉担保的后果层是种类上的自相矛盾：它要求智能体的对手方去做这层本应替他们省去的那件事。

R2 —— 确定性结算：核查即清算。 智能体证明有效的那个动作，必须就是被清算的那个动作。若一笔交易的效果取决于打包时刻的全局状态——取决于同区块还落进了什么、以何种次序——那么本地核查的结果与全局清算的结果就会分叉，而这道缝隙会被收割：抢跑、夹击、在决策与最终性之间被抽取的价值 [17]。对人类交易者这是一笔成本；对以机器速度交易的智能体则是致命的，因为它的合规证明是针对一个在结算时已不再成立的状态算出的。本地验证必须等于全局状态转移（图 2b），否则约束是针对一个不会到来的世界做出的核查。

R3 —— 富表达力、保护隐私的证明。 基底必须能表达谓词，而不只是转移，并且必须允许它们在不披露的情况下被证明——否则合规是以监控换来的，而一个为委托人行动的智能体会在每次动作中泄露委托人的仓位、对手方与策略。它还必须可组合：证明之证明，使核查系统自身的历史不至于又成为无界的工作量。私密智能合约的理论基础把这一点落到实处 [20]，而同构的链下执行让同样的规则在规模上运行、并如同在基础层上算出那样返回 [19]。

R4 —— 无所有者的经济。 排序、存储与可用性总要有有人买单。若由一家公司买单，这家公司便能审查与两面陈述，约束层于是沦为一个多了几道手续的私有数据库——可信第三方被重建。基底因此需要一种内部资源，向一个无许可的群体购买安全与运营 [22, 23]；这——而非投机——才是原生资产承重的角色。有所有者的验证者是公证人；有自筹资金公地的验证者才是基础设施。

R5 —— 能自我修订的规则。 谓词、证明系统与参数都将改变；密码学会老化，政策有争议。不可修订的基底会僵化；由基金会或公司修订的基底则有主（又是 R4，上移一层）。剩下的选项是宪法的：通过留痕的、受规则约束的链上程序修订，且该程序自身的正当性也可被核查 [24]。这是任何地方都最未定的一项要求，诚实的立场是：它是一个开放的制度问题，而非已解的工程问题。

这五项要求把整个领域分了类。仅记值的账本满足 R1 与一种强形式的 R4，却彻底不满足 R3：它无法表达智能体授权所用的谓词。主流的账户模型链富于表达，却交出了 R2——其依赖次序的执行正是可抽取价值的原生栖息地 [17]——于是智能体核查过的动作不是清算的动作。许可链与联盟链通过放弃 R4 来重获确定性与表达力：它们的验证者是具名且经准入的，而这恰恰是智能

表 2: 代理级约束层的五项要求：每项为委托方保障了什么，以及一个已部署实例（§5）所用的机制。文献为一手设计文献。

要求	为委托方保障什么	机制（个案）
R1 可证共识	基础层本身无须被信任	Ouroboros PoS [15, 16]
R2 确定性结算	核查的动作即清算的动作	扩展 UTXO [18]
R3 私密可组合证明	合规而不泄露仓位	Hydra; Kachina/Midnight [19, 20]
R4 无主经济	无任何一方能审查该智能体	质押奖励 [23]
R5 自我修订规则	授权语言可演进	链上宪法 [24]

体的对手方必须信任的那个可信第三方。而多数设计对 R5 保持沉默。这五项两两满足容易，同时满足很难；正因如此，任何一个联合解的存在都值得审视，而非被假定。

5 一个已部署的架构

我们以一个系统对照 R1–R5: Cardano，选择它，是因为其文档化的设计决策——其中数项长期被批评为过度工程——与这五项的对应完整度罕见。这里的主张是架构对应，不是市场胜利；个案的价值在于，它把「这五项能否同时满足？」从一个愿望变成一个存在性问题，且至少有一个肯定的实例。我们依次检读诸要求，然后坦陈个案的负债。

R1 共识层是一族权益证明协议，其安全性在显式的敌手模型下得到证明——先是同步、继而是带自适应腐化的半同步 [15, 16]。方法论意义高于密码学意义：一个出售「核查、勿信」的层，已把自身的基础层安全做成可核查的主张而非一句保证，而这正是其对手方在上一层所依赖的纪律。

R2 账本模型把比特币的未花费输出纪律延伸到完整合约，同时保住其决定性性质：一笔交易的有效性、效果与费用，由它自身的输入在本地、在提交之前确定 [18]。智能体证明的就是链上清算的。为富表达共享状态而优化的账户型架构恰恰交出了这一点，而「核查」与「清算」之间的分叉正被工业化抽取 [17]。在本论题之下，确定性不是一种性能口味；它使一个智能体的动作成为关于其自身效果的可证主张，而非投进一场它看不见的拍卖的出价。

R3 表达力分层到达，且不向非用户征税。链上脚本承载公开谓词；状态通道把计算同构地抬到链下，在同一语义下运行同样的脚本，使返回的结果如同在基础层上算出 [19]；而一个以私密智能合约理论为根基的伙伴网络 [20] 运行的谓词，能在只披露谓词本身的前提下证明合规 [21]。这正是智能体授权所需的选择性披露体制：证明规则，保留仓位。

R4 区块生产向一个无许可的质押池群体购买，奖励方案经工程化设计使其在多个独立运营者处达到均衡 [23]，协议开发则由链上金库出资。基底以自己的资源为自己的中立性付费——这就是开




图 2: 受界委托与确定性鸿沟。(a) 委托人编译策略 φ ；智能体的动作 a 携带证明 $\pi(a \vdash \varphi)$ 同行，由对手方核查；结算与审计化归为对照公共账本 L 重放证明。权限在事前受界。(b) 为何确定性 (R2) 承重：在非确定性轨道上，核查与打包之间的重排或插入会清算出一个状态 $s' \neq s_0$ ，于是智能体已验证的动作不是被清算的那个；在确定性轨道上，动作的输入固定其效果，核查即清算。示意图。

放公地与如今以「企业级区块链」出售的联盟出函服务之间的类差：后者有所有者，因而重新引入了智能体对手方必须信任的那一方。

R5 自 2023 年起，该系统在一部经批准的宪法之下运行由受托代表、质押池运营者与宪法委员会组成的链上治理，每一项动议都在公共记录上 [24]。这套安排年轻，第一批宪法危机也已到来；这并不构成否决，因为 R5 在任何地方都未被解决，而此处要紧的是：修订程序坐落于被验证的记录之内，而非紧邻的董事会里。

诚实的检读须陈明负债。基础层吞吐量远低于中心化轨道；证明系统带来真实的证明与验证开销；应用层生态有目共睹地挣扎，采用落后于架构数年；R5 的治理尚不成熟且有争议。这些都未被本论题掩盖，也都不是本论题的主题：个案立足于五项要求的联合满足，而 §7 写明了何种证据将推翻这一检读。

6 智能体商业的形态

这些部件组合成单一的模式（图 2a）。委托人不把密钥交给智能体；它编译一份策略 φ ——支出上限、对手方类别、升级条件——而智能体的权限就是 φ 。智能体的每一个动作都携带一份证明，证明该动作满足 φ ；对手方在行动前核查该证明，于是边界由受其保护的一方强制执行，而非靠委托人寄望。结算发生在确定性轨道上，于是被验证的动作就是被做成最终的动作 (R2)；又因为每一步都对照公共账本留痕，审计便不是争议之后的取证重构，而是对早已在册的证明的一次重放。权限在事前受界；问责在事后机械化。

这不是关于智能体可能如何交易的预测；它大致就是第一批标准已经声明的交易方式。如今正在落地的智能体支付协议，把每一笔购买锚定到一串签名授权凭证，正是为了让授权建立在可验证的意图、而非模型的一面之词之上 [10, 11]，而账户抽象提供了授权凭证所针对的那份受界、可

撤销的凭证 [12]。它们尚未提供的，是 R2 的基底保证：它们多数结算在账户模型轨道上，核查的动作与清算的动作仍可能分叉 [17]。互补关系的需求侧正在公开地被建造；能让它在机器速度下安全的那份确定性，才是仍然缺失的一半，§7 把它当作真正的检验来对待。

身份沿同一条线分解。对手方必须回答的问题——这是什么，谁在背后？——分解为可核查的谓词。在需要之处，人格成为行为者可以证明而非断言之物 [25]；智能体凭证通过来源本身可核查的签名回链至一个可问责的委托人 [26]；而智能体所产之物的出处，可以作为一份签名的主张随之同行，而不是留给某个检测器去事后猜疑 [27]。每一处，动作都与定义整个架构的那个动作相同：以事前附着的证明，取代对一件流利人造物的事后判断。

由此有两点观察。其一关乎成本。人类把这套机制体验为摩擦——密钥、钱包、出函，一种比径直被信任更差的体验——这正是面向人类的加密始终难以要紧的原因。智能体体验到的恰好相反：声誉是它们天生持有不了的东西，而生成与核查证明正是它们以原生速度所做之事；它们不疲倦、不会看错地址，也无法通过一个只接纳有效动作的基底被社会工程。那种把人类用户推开的摩擦，对正在到来的群体而言是无重量的。其二关乎契合的方向。生成式 AI 是需求：它产出决策的速度，快过任何可信的人类机构所能审核。可验证的、确定性的结算，是唯一一种吞吐量随算力而非随注意力扩展的供给回应。二者不是争夺同一叙事位置的对手：一个使决策充裕，另一个使决策绑定——而一个无法绑定的决策，在经济意义上，不过是空话。

7 开放问题与可证伪

本论题是一个技术上的赌注，而一个诚实的赌注要同时写明它未解的部分，以及何种证据将把它判输。

四个问题是开放的。成本与延迟：为每一个动作出证并不免费，一个持续交易的智能体可能产生证明的速度，快过它们能被廉价地生成或验证的速度；自携证明的结算能否以可接受的成本满足机器速度的商业，尚无定论，而递归组合（R3）是部分答案，不是完成的答案。治理（R5）：在被验证的记录之内自我修订，尚且年轻、参与稀薄、且已承压；没有任何系统证明过一部宪法能在既不被俘获也不陷入瘫痪的情况下演进一套证明语言与一套费用政策。谓词问题：一份授权的好坏，取决于委托人实际能表达的策略 φ ，而为开放式行为书写 φ ——预先设想一个智能体绝不可做之事——其难度可能不亚于它所类比的对齐问题；基底强制执行 φ ，却不撰写它。自举：约束层在智能体与对手方都已使用它时最有用，这是经典的采用陷阱，架构上的适配并不能化解它。

四项观察将证伪这一论述。最早的智能体支付标准如今恰恰结算在非确定性轨道上 [11]；若智能体商业随规模增长仍滞留于此、不为可抽取价值之税 [17] 所动，那么 R2 关于「智能体愿意付费去避免什么」的判断就是错的，确定性并不承重。若出处与智能体身份聚拢为少数平台出函服务——设备厂商、应用商店、模型供应商——那么无主基底（R4）便输给了一个重新中心化的方案，证词体制只是以更高的集中度、配上根密钥被重建；在我们看来，这是本论题失败的最可能方式，而它是市场结构问题，不是可行性问题。若技术进展使智能体在内部变得可绑定——在模型栈自身之内承载硬件背书的、可验证的执行——那么外部基底便是多余的，互补关系随之消解。又若在开放基底之间，为结算、出证与出函所付费用的份额，始终未能超过为投机换手所付的份额，那么这

些系统就是赌场而非基础设施，无论其设计如何——§5 的个案对这项检验，刻意不予豁免。

8 结语：谁来书写规则

分工就是全部论证。一个生成式模型供给决策；一个确定性的、自携证明的、无主的基底供给后果；二者合起来，造出一个可被委托、可受界、可问责的自主行为者——而任一半单独都做不到。这不是一个机器取代制度的故事。这是一个为非人类行为者重建那件制度曾为人类所做之事的故事：把一个决策转化为一个绑定的承诺。

有一种能力，在这道分工的两侧都不出现。基底强制执行策略 φ ；智能体在其内行动；但 φ 的抉择——一个智能体绝不可做什么、什么算作合规、哪些结果值得被做成不可逆——由两者皆非。书写规则不是一项可委托给智能体的任务，因为它正是界定其下每一次委托之边界的那个动作；它也不是基底执行的一项计算，因为基底只核查。它是约束的撰写，并停留在那个承担「写错了的后果」的人身上。当决策变得充裕、其结算变得自动，稀缺而承载后果的动作便不再是决策，也不再是执行。它是：预先地、并留诸记录地，言明什么应当、什么不应当被允许绑定。

数据可得性 本文为理论贡献；不报告任何实验、任何实证数据集。所有主张均依托于所引文献；复现插图所需的脚本与材料随代码一并发布。

代码可得性 两幅插图均为示意图，由公开发布于 <https://github.com/xinhao-zheng/constraint-layer> 的脚本生成；未绘制任何经验序列。

作者贡献 X.Z. 构思论证、设计插图并撰写全文。

利益冲突 作者不持有文中讨论的任何资产头寸，亦未接受任何被提及实体的资助。

伦理说明 不涉及人类受试者。系统与产品名称仅作描述性使用；个案分析是架构性的，不构成投资建议。

参考文献

- [1] North, D. C. (1990). *Institutions, Institutional Change and Economic Performance*. Cambridge University Press.
- [2] Arrow, K. J. (1974). *The Limits of Organization*. Norton, New York.
- [3] Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., and Bernstein, M. S. (2023). Generative agents: Interactive simulacra of human behavior. In *UIST 2023*. ACM.
- [4] Chan, A., Salganik, R., Markelius, A., et al. (2023). Harms from increasingly agentic algorithmic systems. In *ACM FAccT 2023*, pages 651–666.

- [5] Sadasivan, V. S., Kumar, A., Balasubramanian, S., Wang, W., and Feizi, S. (2023). Can AI-generated text be reliably detected? *arXiv:2303.11156*.
- [6] Zhang, H., Edelman, B. L., Francati, D., Venturi, D., Ateniese, G., and Barak, B. (2023). Watermarks in the sand: Impossibility of strong watermarking for generative models. *arXiv:2311.04378*.
- [7] Necula, G. C. (1997). Proof-carrying code. In *POPL '97*, pages 106–119. ACM.
- [8] Goldwasser, S., Micali, S., and Rackoff, C. (1989). The knowledge complexity of interactive proof systems. *SIAM Journal on Computing*, 18(1):186–208.
- [9] Ben-Sasson, E., Chiesa, A., Garman, C., Green, M., Miers, I., Tromer, E., and Virza, M. (2014). Zerocash: Decentralized anonymous payments from Bitcoin. In *IEEE Symposium on Security and Privacy*, pages 459–474.
- [10] Google and partners (2025). *Agent Payments Protocol (AP2): An Open Protocol for Agent-Led Payments*. Technical specification, September 2025.
- [11] Coinbase and Cloudflare (2025). *x402: An Open Standard for Internet-Native Payments over HTTP 402*. x402 Foundation.
- [12] Buterin, V., Weiss, Y., Tirosh, D., Nacson, S., and Forshtat, A. (2021). ERC-4337: Account abstraction using an alt mempool. *Ethereum Improvement Proposals*.
- [13] Szabo, N. (1997). Formalizing and securing relationships on public networks. *First Monday*, 2(9).
- [14] Catalini, C. and Gans, J. S. (2020). Some simple economics of the blockchain. *Communications of the ACM*, 63(7):80–90.
- [15] Kiayias, A., Russell, A., David, B., and Oliynykov, R. (2017). Ouroboros: A provably secure proof-of-stake blockchain protocol. In *CRYPTO 2017*, LNCS 10401, pages 357–388. Springer.
- [16] David, B., Gaži, P., Kiayias, A., and Russell, A. (2018). Ouroboros Praos: An adaptively-secure, semi-synchronous proof-of-stake blockchain. In *EUROCRYPT 2018*, LNCS 10821, pages 66–98. Springer.
- [17] Daian, P., Goldfeder, S., Kell, T., Li, Y., Zhao, X., Bentov, I., Breidenbach, L., and Juels, A. (2020). Flash boys 2.0: Frontrunning in decentralized exchanges, miner extractable value, and consensus instability. In *IEEE Symposium on Security and Privacy*, pages 910–927.
- [18] Chakravarty, M. M. T., Chapman, J., MacKenzie, K., Melkonian, O., Peyton Jones, M., and Wadler, P. (2020). The extended UTXO model. In *Financial Cryptography Workshops (WTSC)*, LNCS 12063, pages 525–539. Springer.
- [19] Chakravarty, M. M. T., Coretti, S., Fitzi, M., Gaži, P., Kant, P., Kiayias, A., and Russell, A. (2021). Hydra: Fast isomorphic state channels. *Cryptology ePrint Archive*, Report 2020/299.
- [20] Kerber, T., Kiayias, A., and Kohlweiss, M. (2021). Kachina: Foundations of private smart contracts. In *IEEE Computer Security Foundations Symposium*, pages 47–62.
- [21] Midnight Foundation (2024). *Midnight: A Data-Protection Blockchain—Technical Overview*. Project documentation.
- [22] Nakamoto, S. (2008). Bitcoin: A peer-to-peer electronic cash system. White paper.
- [23] Brünjes, L., Kiayias, A., Koutsoupias, E., and Stouka, A.-P. (2020). Reward sharing schemes for stake pools. In *IEEE European Symposium on Security and Privacy*, pages 256–275.
- [24] Cardano community (2023). *CIP-1694: An On-Chain Decentralized Governance Mechanism for*

Voltaire. Cardano Improvement Proposals.

- [25] Borge, M., Kokoris-Kogias, E., Jovanovic, P., Gasser, L., Gailly, N., and Ford, B. (2017). Proof-of-personhood: Redemocratizing permissionless cryptocurrencies. In *IEEE EuroS&P Workshops*, pages 23–26.
- [26] Diffie, W. and Hellman, M. E. (1976). New directions in cryptography. *IEEE Transactions on Information Theory*, 22(6):644–654.
- [27] Coalition for Content Provenance and Authenticity (2024). *C2PA Technical Specification, v2.0*. Standard.